

BLOC E • SÉANCES 12 À 13

Ouverture : RAG et agents

Faire parler un modèle de vos données



Les séances de ce bloc

1

Séance 12

Embeddings, bases vectorielles et RAG

2

Séance 13

Agents ReAct, et TP RAG

SÉANCE 12 • OUVERTURE

Embeddings, bases vectorielles et RAG

Faire répondre un modèle sur des données qu'il n'a jamais vues

1

Au programme aujourd'hui

1

Constater

Le modèle ne connaît pas vos données, et ne les connaîtra pas

2

Comparer

Chercher par le sens plutôt que par les mots

3

Assembler

Le pipeline RAG, étape par étape

4

Douter

Les six endroits où un RAG casse en production

Vos données ne sont pas dans le modèle

- Le modèle a été entraîné avant votre projet, sur des données publiques.
- Il ne connaît ni votre catalogue, ni vos tickets, ni votre documentation.
- Interrogé dessus, il n'échoue pas : il invente, avec aplomb.



Trois réponses possibles, une seule raisonnable

Réentraîner : hors de portée. Affiner : cher et figé. Fournir le bon extrait dans le prompt : c'est le RAG.

Affiner le modèle, ou lui fournir le contexte

Fine-tuning

- Coûteux en calcul et en données
- Fige la connaissance au jour J
- Aucune citation de source possible
- Utile pour un style, un format
- Rarement la réponse à votre problème

RAG

- Aucun entraînement, juste de la recherche
- Les données changent quand vous voulez
- Les sources sont citables
- Utile pour de la connaissance
- La réponse par défaut, dans 90 % des cas

Chercher par le sens, pas par les mots

Un utilisateur écrit « je n'ai rien reçu » ; votre doc dit « colis non livré ».

- **La recherche par mots-clés** : aucun mot commun, donc aucun résultat, alors que c'est le bon document
- **La recherche sémantique** : les deux phrases donnent des vecteurs proches, donc le document remonte
- **La mesure** : la similarité cosinus, entre -1 et 1 : on garde les plus proches
- **Le prix à payer** : elle rate les termes exacts, références et codes produits : d'où les approches hybrides

Toute la magie tient en trois lignes

```
def similarite(a, b):  
    return a @ b / (norm(a) * norm(b))  
  
v1 = plonger("le colis est arrive casse")          # 768 nombres  
v2 = plonger("article endommagement pendant le transport")  
v3 = plonger("modifier mon adresse email")  
  
print(similarite(v1, v2), similarite(v1, v3))  
0.711    0.136
```

Chiffres réellement mesurés avec paraphrase-multilingual. Aucun mot commun entre v1 et v2, et pourtant 0,71.

Le modèle d'embedding se choisit sur mesures

Modèle	Paires proches	Paires éloignées	Écart
nomic-embed-text	0,542	0,578	-0,036
paraphrase-multilingual	0,527	0,249	+0,278

Mesuré pour ce cours sur 8 paires françaises. Le premier, très populaire, est entraîné sur de l'anglais : son écart est négatif.

Un modèle très recommandé peut être inutilisable

- nomic-embed-text est le modèle d'embedding le plus conseillé en ligne.
- Sur des phrases françaises courtes, il inverse trois paires sur quatre.
- Il ne rapproche pas ce qui se ressemble : il fait pire que le hasard.



Le cas s'est produit ici même

Ce cours devait utiliser nomic-embed-text. La mesure, faite avant vous, a imposé d'en changer. C'est la séance 11 en situation réelle.

Le RAG, de bout en bout



Les trois premières étapes sont de la recherche d'information classique. Seule la dernière fait appel à un LLM.

Où mettre les vecteurs

Solution	Quand la choisir	Coût d'entrée
Un tableau en mémoire	moins de 5 000 morceaux	nul
SQLite ou un fichier	prototype persistant	très faible
pgvector	vous avez déjà PostgreSQL	une extension
Qdrant, Chroma	gros volume, filtres riches	un service de plus

Pour le TP et pour la plupart de vos projets d'école, la première ligne suffit largement.

Le découpage décide de la qualité

C'est l'étape la plus négligée, et celle qui fait rater les réponses.

- **Trop gros** : l'extrait noie l'information utile et remplit le contexte
- **Trop petit** : la phrase perd son contexte et devient incompréhensible
- **Le repère usuel** : 300 à 800 tokens, avec un recouvrement de 10 à 15 %
- **Mieux que la taille** : découper sur la structure : titres, sections, articles

Les endroits où un RAG casse

Un RAG qui répond mal est presque toujours un RAG qui a mal cherché.

- **La recherche a raté** : le bon extrait n'est jamais remonté : le modèle n'y peut rien
- **Le contexte est saturé** : vingt extraits injectés, le modèle ne lit que les premiers
- **Il invente malgré les sources** : il faut lui interdire de répondre hors extraits, explicitement
- **Aucune traçabilité** : sans citation, personne ne peut vérifier, donc personne ne fait confiance

Embeddings et RAG

- ✓ Le modèle ne connaît pas vos données : on les lui fournit au moment de la question.
- ✓ La recherche sémantique compare des vecteurs, pas des mots.
- ✓ Le pipeline : découper, vectoriser, chercher, répondre en citant.
- ✓ Un modèle d'embedding se choisit sur mesures, et doit parler votre langue.
- ✓ La qualité d'un RAG se joue au découpage et à la recherche, pas au modèle.

SÉANCE 13 • OUVERTURE

Agents ReAct, et TP RAG

Ce que recouvre le mot « agent », et ce qu'il coûte

1

Au programme aujourd'hui

1

Distinguer

Chaîne de prompts, outil, agent : trois choses différentes

2

Dérouler

La boucle ReAct : penser, agir, observer

3

Relativiser

Le prix réel de l'autonomie

4

Construire

Un RAG minimal sur vos propres documents

Trois montages qu'on appelle tous « agent »

Chaîne de prompts

- Vous écrivez les étapes
- L'ordre est fixe et connu
- Testable, prévisible
- Couvre l'immense majorité des besoins

Agent autonome

- Le modèle choisit les étapes
- L'ordre change à chaque exécution
- Difficile à tester
- Justifié quand le chemin est inconnu

Penser, agir, observer, recommencer

1

Pensée

Le modèle formule ce qu'il cherche à faire.

2

Action

Il demande un outil, avec des arguments.

3

Observation

Vous exécutez et lui rendez le résultat.

4

Boucle

Il recommence, jusqu'à pouvoir répondre.

À quoi ressemble une exécution, vue des journaux

Question : la commande CMD-118 est-elle partie ?

Pensee : il me faut le statut de cette commande

Action : `chercher_commande({"numero": "CMD-118"})`

Observation: `{"statut": "expediee", "transporteur": "X"}`

Pensee : il me faut le delai de ce transporteur

Action : `delai_transporteur({"nom": "X"})`

Observation: `{"jours": 3}`

Reponse : oui, expediee, livraison sous 3 jours.

Trois appels au modèle pour une réponse. C'est le vrai prix de l'autonomie : il se paie en latence et en tokens.

Standardiser le branchement des outils

Model Context Protocol : un format commun pour exposer outils et données.

- **Le problème résolu** : chaque application redéfinissait ses outils dans son coin
- **Le principe** : un serveur expose des outils, n'importe quel client compatible les consomme
- **Ce que ça change pour vous** : un outil écrit une fois, réutilisable ailleurs
- **Ce que ça ne change pas** : la validation, les droits et les limites restent votre responsabilité

Pourquoi on n'en met pas partout

Chaque tour de boucle est un appel complet au modèle.

- **Le coût se multiplie** : cinq tours, c'est cinq fois le prix et cinq fois l'attente
- **Les erreurs s'accumulent** : 90 % de réussite par étape donne 59 % sur cinq étapes
- **Le test devient difficile** : deux exécutions identiques ne suivent pas le même chemin
- **La règle de sagesse** : si vous connaissez les étapes, écrivez-les. Un agent n'est utile que dans l'inconnu

Un RAG minimal, sur vos documents

- 1 Découper le corpus fourni en morceaux de 400 tokens.
- 2 Vectoriser avec paraphrase-multilingual, vecteurs gardés en mémoire.
- 3 Implémenter la recherche des trois extraits les plus proches.
- 4 Injecter les extraits dans le prompt et exiger la citation des sources.
- 5 Poser une question hors corpus et vérifier que le modèle refuse.

Objectif

Construire un RAG complet en une séance, et constater que la difficulté n'est pas dans le modèle mais dans la recherche.

Agents et RAG

- ✓ Une chaîne de prompts couvre presque tous les besoins : préférez-la.
- ✓ ReAct est une boucle : penser, agir, observer, recommencer.
- ✓ L'autonomie se paie en latence, en tokens et en erreurs cumulées.
- ✓ Un agent se justifie quand le chemin est inconnu, pas quand il est long.