

SYNTHÈSE • SÉANCE 14

Synthèse

Reprendre le module, et préparer l'écrit



SÉANCE 14 • SYNTHÈSE

Reprendre le module, et préparer l'écrit

Ce qui sera demandé, et sous quelle forme

1

Au programme aujourd'hui

1

Relier

La carte du module, des tokens jusqu'aux agents

2

Réviser

Le vocabulaire exigible, terme par terme

3

S'entraîner

Un sujet blanc au format du partiel, corrigé ensemble

4

Éviter

Les erreurs qui coûtent des points chaque année

Tout le module en une ligne



Chaque séance a ajouté une brique à cette ligne. Le partiel vous demandera de la parcourir dans les deux sens.

Les termes exigibles, première partie

Terme	Définition attendue en une phrase
Token	l'unité de découpage du texte, facturée et comptée
Embedding	un vecteur qui représente le sens d'un texte
Fenêtre de contexte	tout ce que le modèle voit pendant un appel
Température	le degré de hasard dans le choix du token suivant
Hallucination	une sortie plausible et fausse, sans signal d'erreur
Quantization	réduire la précision des poids pour tenir en mémoire

Les termes exigibles, seconde partie

Terme	Définition attendue en une phrase
Streaming	recevoir la réponse par fragments, en SSE
Sortie structurée	contraindre le format et le valider par un schéma
Injection de prompt	une donnée utilisateur lue comme une consigne
Function calling	le modèle demande un appel, le serveur l'exécute
RAG	chercher les bons extraits et les fournir dans le prompt
ReAct	la boucle penser, agir, observer, recommencer

Le partiel, en trois parties

1

Questions de cours

Définitions et raisonnements courts. Une phrase juste vaut mieux qu'un paragraphe flou.

2

Analyse d'architecture

Un schéma d'intégration à critiquer : frontière, secrets, validation.

3

Cas de décision

Un besoin produit, un choix de modèle à faire et à chiffrer.

Ce qui coûte des points chaque année

Quatre confusions récurrentes, toutes évitables.

- **Confondre entraînement et inférence** : le partiel ne porte que sur l'usage, jamais sur l'apprentissage
- **Croire que la température corrige les erreurs** : elle règle le hasard, pas la véracité
- **Placer la clé côté client** : une seule mention suffit à perdre la question d'architecture
- **Répondre « le meilleur modèle »** : on attend un arbitrage chiffré, pas une préférence

Une heure trente, dans les conditions du partiel

- 1 Traiter le sujet blanc distribué, seul et sans machine.
- 2 Correction collective immédiate, question par question.
- 3 Repérer les questions où le vocabulaire manque.
- 4 Poser les questions restantes sur le CC2.
- 5 Repartir avec le corrigé annoté.

Objectif

Arriver au partiel sans surprise sur le format ni sur les attentes.

Ce qu'il faut retenir du module

- ✓ Un modèle est une fonction apprise : il ne comprend pas, il calcule.
- ✓ Le token est l'unité de tout : coût, latence, contexte.
- ✓ Le navigateur parle à votre serveur, votre serveur parle au modèle.
- ✓ On choisit le plus petit modèle qui passe ses propres cas de test.